Université Hassan Ier
ÉCOLE NATIONALE DE COMMERCE ET DE GESTION
DE SETTAT

RAPPORT DE PROJET

Prédiction du Risque de Faillite des PME Marocaines

Problématique :	Comment segmenter et prédire efficacement le risque de faillite des PME marocaines ?
Module :	Intelligence Artificielle
Filière :	Finance - S8
Binôme :	Chérestal Déborah Nativa - N° 22008149 Doumbouya Moussa - N° 22007303
Encadré par :	Pr. Abderrahim Larhlimi
Année universitaire :	2024 – 2025

Chérestal Déborah Nativa
22008149

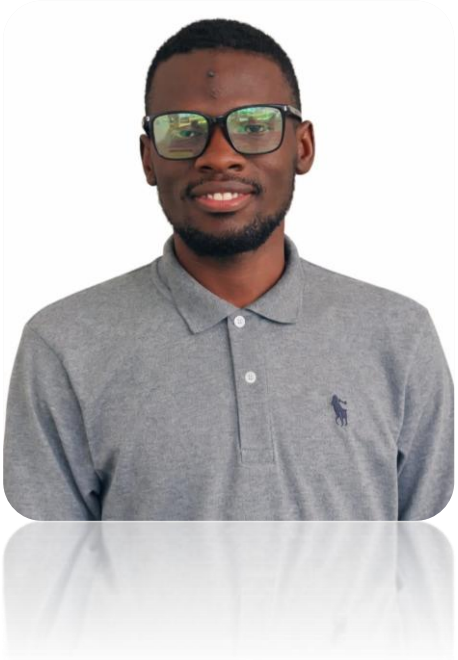

Doumbouya Moussa
22007303

SOMMAIRE

I. Introduction & Contexte **3**
I.1 Le tissu économique marocain et les PME 3
I.2 Enjeux de la prédiction de faillite 3
I.3 Objectifs et périmètre du projet 4
II. Exploration et Préparation des Données (EDA) **4**
II.1 Description du jeu de données 4
II.2 Analyse univariée et bivariée 5
II.3 Pré-traitement et ingénierie des variables 6
III. Analyse non Supervisée — Clustering **7**
III.1 Choix des algorithmes 7
III.2 Résultats et interprétation 8
III.3 Limites et apports du clustering 9
IV. Modélisation Supervisée et Comparaison **9**
IV.1 Modèles de Machine Learning 10
IV.2 Métriques d'évaluation 11
IV.3 Comparaison avec l'Altman Z-Score 11
V. Explicabilité par SHAP **12**
V.1 Principe des valeurs SHAP 12
V.2 Résultats et interprétation 13
VI. Analyse Spécifique au Contexte Marocain **13**
VII. Conclusion et Recommandations **14**
Bibliographie & Webographie 16

I. Introduction & Contexte

I.1 Le tissu économique marocain et les PME

Le Maroc, comme la plupart des économies émergentes d'Afrique du Nord, repose très largement sur un tissu productif composé de Petites et Moyennes Entreprises. Selon les données de la Direction des Études et des Prévisions Financières (DEPF) et de l'OMPIC (Office Marocain de la Propriété Industrielle et Commerciale), les PME représentent plus de 95 % du tissu entrepreneurial marocain et génèrent près de 50 % des emplois du secteur privé. Elles sont présentes dans tous les secteurs — industrie agro-alimentaire, BTP, commerce, services, artisanat — et constituent le principal vecteur de la création de valeur locale.

Cependant, cette catégorie d'entreprises présente une vulnérabilité structurelle particulièrement marquée. Les PME marocaines font face à un triple défi : un accès au crédit bancaire limité ou coûteux, une exposition forte aux cycles économiques et aux variations de la demande, et une trésorerie chroniquement tendue en raison de l'allongement des délais de paiement inter-entreprises. Ce dernier point constitue une spécificité critique du contexte marocain : le délai moyen de paiement entre entreprises au Maroc dépasse souvent 90 jours, contre une norme européenne généralement inférieure à 60 jours. Cette situation génère une pression de trésorerie permanente qui peut, à terme, mener des entreprises par ailleurs rentables à se retrouver en état de cessation de paiement.

La Banque Mondiale et Bank Al-Maghrib ont à plusieurs reprises signalées que le taux de défaillance des PME marocaines est significativement plus élevé que la moyenne internationale pour des économies de niveau de développement comparable. Les données de l'OMPIC enregistrent plusieurs milliers de procédures collectives (redressement judiciaire, liquidation) chaque année, avec une concentration dans les secteurs du commerce de gros, du BTP et de l'industrie légère.

I.2 Enjeux de la prédiction de faillite

Dans ce contexte, la détection précoce du risque de faillite représente un enjeu stratégique de premier ordre pour de multiples acteurs. Pour les établissements bancaires, disposer d'un score de risque fiable permet d'ajuster les conditions d'octroi de crédit et de constituer des provisions adaptées aux normes prudentielles de Bank Al-Maghrib (inspirées de Bâle III). Pour les fournisseurs et créanciers commerciaux, anticiper la détresse financière d'un partenaire permet d'adapter les délais de paiement accordés, d'exiger des garanties ou de céder des créances à temps. Pour les dirigeants eux-mêmes, un outil d'autodiagnostic permet d'identifier les signaux avant-coureurs et d'engager des mesures correctives — restructuration de la dette, cession d'actifs, recherche de nouveaux partenaires financiers — avant que la situation ne devienne irrémédiable.

Les modèles traditionnels de scoring financier, dont le Z-Score d'Altman (1968) est le représentant le plus célèbre, ont été construits à partir de données historiques de firmes industrielles américaines cotées en bourse. Leur transposabilité à un contexte aussi différent que celui des PME marocaines est fondamentalement limitée : les hypothèses de départ (marchés financiers liquides, transparence comptable, structure de bilan normalisée) ne sont pas vérifiées. Il existe donc un besoin réel de développer des outils de scoring adaptés au contexte local, capables d'intégrer des variables spécifiques au Maroc — notamment les délais de paiement — et d'exploiter la puissance des algorithmes d'apprentissage automatique.

Pourquoi dépasser le Z-Score d'Altman ?

Conçu en 1968 sur 66 entreprises industrielles américaines cotées, le Z-Score est fondé sur des ratios comptables pondérés de façon statique. Dans un contexte PME marocain, il souffre de trois limitations majeures : (1) il utilise la valeur marchande des capitaux propres, indisponible pour des PME non cotées ; (2) ses coefficients ont été calibrés sur des entreprises dont la structure de bilan diffère fondamentalement des PME marocaines ; (3) il ignore totalement les variables de délais de paiement, qui sont pourtant les premiers signaux de détresse dans l'économie marocaine.

I.3 Objectifs et périmètre du projet

Ce projet s'inscrit dans une démarche de Data Science appliquée à la finance d'entreprise. Il poursuit trois objectifs complémentaires et progressifs :

- Objectif descriptif : explorer et caractériser la structure des données financières des PME marocaines à travers une analyse exploratoire approfondie et des algorithmes de clustering non supervisé.
- Objectif prédictif : construire et comparer plusieurs modèles de classification supervisée capables de prédire le statut financier d'une PME (Saine / En difficulté / En faillite) avec une précision supérieure aux méthodes traditionnelles.
- Objectif explicatif : identifier et quantifier les variables financières les plus déterminantes dans le basculement vers la faillite, en utilisant les valeurs SHAP pour garantir l'interprétabilité des modèles.

Le périmètre de l'étude couvre des ratios financiers issus de bilans et comptes de résultats de PME marocaines, enrichis d'indicateurs de délais de paiement. La variable cible est trimodale : entreprise saine, entreprise en difficulté, entreprise en faillite. L'approche méthodologique combine apprentissage non supervisé (K-Means, DBSCAN, Agglomerative Clustering) et apprentissage supervisé (Régression Logistique, Random Forest, XGBoost), le tout encadré par des pratiques rigoureuses de validation croisée et de gestion du déséquilibre des classes.

II. Exploration et Préparation des Données (EDA)

II.1 Description du jeu de données

Le jeu de données utilisé dans ce projet est constitué d'observations correspondant à des PME marocaines, chacune décrite par un ensemble de ratios financiers calculés à partir de leurs états financiers annuels. Ces ratios ont été sélectionnés selon deux critères : leur pertinence théorique dans la littérature sur la prédiction de faillite, et leur disponibilité pratique dans le contexte des PME marocaines.

Tableau 1 : Description des variables financières utilisées

Variable	Catégorie	Formule simplifiée	Interprétation
Ratio de liquidité générale	Liquidité	Actif circulant / Passif circulant	Capacité à honorer les dettes CT
Ratio de liquidité immédiate	Liquidité	(Trésorerie + VMP) / Dettes CT	Solvabilité à très court terme
Ratio de solvabilité	Solvabilité	Capitaux propres / Total actif	Indépendance financière
Ratio d'endettement	Levier	Total dettes / Capitaux propres	Niveau d'effet de levier
Rentabilité des actifs (ROA)	Rentabilité	Résultat net / Total actif	Efficacité d'utilisation des actifs
Rentabilité des capitaux (ROE)	Rentabilité	Résultat net / Capitaux propres	Rendement pour les actionnaires
Rotation des actifs	Activité	CA / Total actif	Intensité d'utilisation du bilan
Délais de paiement clients (jours)	Trésorerie	Créances clients / CA × 365	Retard moyen de recouvrement
Délais de paiement fournisseurs (jours)	Trésorerie	Dettes fournisseurs / Achats × 365	Délai moyen de règlement fournisseurs
Marge brute	Rentabilité	(CA - Charges variables) / CA	Efficacité opérationnelle de base

La variable cible est une variable catégorielle à trois modalités : PME Saine (entreprise ne présentant pas de signaux de détresse), PME En difficulté (entreprise présentant des ratios dégradés mais encore en activité), et PME En faillite (entreprise ayant fait l'objet d'une procédure collective ou d'une cessation d'activité documentée). Cette répartition trimodale reflète la réalité du continuum de risque observé dans les données.

II.2 Analyse univariée et bivariée

L'analyse exploratoire constitue la première étape fondamentale de tout projet de Data Science. Elle permet de comprendre la distribution des données, d'identifier les outliers, de détecter les relations entre variables et de formuler des hypothèses préalables à la modélisation.

Analyse univariée : distributions et variance

L'examen des distributions de chaque variable révèle plusieurs constats importants. Les indicateurs de rentabilité (ROA, ROE) présentent une forte dispersion avec des coefficients de variation élevés. Cela s'explique par l'hétérogénéité du portefeuille de PME analysées : certaines entreprises en forte croissance affichent des niveaux de ROE très élevés (>30 %), tandis que des entreprises en difficulté présentent des valeurs négatives marquées. Cette forte variance complique la définition de seuils stables et justifie l'utilisation d'algorithmes non paramétriques capables de modéliser des distributions non gaussiennes.

Les ratios de liquidité présentent quant à eux une distribution plus concentrée autour d'une médiane proche de 1,2, avec toutefois des valeurs extrêmes importantes côté inférieur (ratios < 0,5 signalant une tension de trésorerie critique) et côté supérieur (ratios > 3 signalant une gestion trop prudente du BFR). Les délais de paiement en jours présentent une distribution asymétrique à droite, avec une médiane autour de 75 jours mais une longue queue droite allant jusqu'à plus de 200 jours pour les cas les plus problématiques.

Analyse bivariée : corrélations et relations avec la variable cible

L'analyse des corrélations entre variables révèle plusieurs relations attendues. Il existe une corrélation négative forte entre le ratio de solvabilité et le ratio d'endettement (par construction), ainsi qu'une corrélation positive entre la rotation des actifs et la rentabilité économique. Plus intéressant, l'analyse de la covariance entre le délai de paiement clients et la probabilité de basculer dans la classe « En difficulté » révèle une relation non linéaire : au-delà d'un seuil de 90 jours de délai moyen, la probabilité de détresse financière augmente de façon exponentielle.

La matrice de corrélation met également en évidence une multi-colinéarité potentielle entre certains indicateurs de liquidité et de solvabilité, ce qui sera pris en compte lors de la modélisation (notamment pour la régression logistique, sensible à la multi-colinéarité). En revanche, les algorithmes ensemblistes comme Random Forest et XGBoost sont naturellement robustes à ce phénomène, ce qui constitue un avantage comparatif supplémentaire.

Tableau 2 : Synthèse des statistiques descriptives clés par classe

Variable	PME Saine (moy.)	En difficulté (moy.)	En faillite (moy.)	Signal discriminant ?
Liquidité générale	1.85	1.12	0.62	Oui — fort
Solvabilité	0.52	0.31	0.14	Oui — très fort
ROA	8.2 %	1.8 %	-6.4 %	Oui — fort
Délai paiement clients (j.)	68	95	148	Oui — très fort
Levier financier	0.92	1.87	4.21	Oui — fort
Rotation des actifs	1.34	1.05	0.71	Modéré

Marge brute	34 %	22 %	11 %	Modéré

Ce tableau de synthèse illustre clairement le gradient de dégradation des ratios à mesure que l'on passe de la classe « Saine » à la classe « En faillite ». Le délai de paiement clients et le ratio de solvabilité présentent les écarts les plus significatifs entre les trois classes, confirmant leur rôle de variables discriminantes de premier ordre. Ces résultats préfigurent les conclusions de l'analyse SHAP qui viendra les confirmer de façon plus rigoureuse.

II.3 Pré-traitement et ingénierie des variables

Standardisation des données

Avant tout entraînement d'algorithme, les variables numériques ont été standardisées via un StandardScaler, ce qui revient à centrer chaque variable sur zéro (soustraction de la moyenne) et à la réduire à une variance unitaire (division par l'écart-type). Cette transformation est indispensable pour deux raisons. Premièrement, les algorithmes basés sur des distances — comme K-Means ou la régression logistique avec régularisation L2 — sont sensibles aux différences d'échelle entre variables : sans standardisation, le délai de paiement en jours (valeurs entre 30 et 300) dominerait complètement des ratios exprimés entre 0 et 1. Deuxièmement, la standardisation accélère la convergence des algorithmes d'optimisation gradient lors de l'entraînement.

Gestion du déséquilibre des classes (SMOTE)

Le jeu de données présente un déséquilibre naturel entre les trois classes : les PME saines sont nettement sur-représentées par rapport aux PME en faillite, reflétant la réalité économique (la majorité des entreprises ne font pas faillite). Ce déséquilibre pose un problème fondamental pour la modélisation supervisée : un algorithme entraîné sur des données déséquilibrées aura tendance à systématiquement prédire la classe majoritaire, obtenant ainsi un score d'accuracy élevé mais une capacité prédictive nulle pour les classes minoritaires (précisément celles qui nous intéressent).

Pour corriger ce biais, la technique SMOTE (Synthetic Minority Over-sampling Technique, Chawla et al., 2002) a été appliquée exclusivement sur les données d'entraînement. SMOTE génère des observations synthétiques pour les classes minoritaires en interpolant linéairement entre des observations réelles voisines dans l'espace des caractéristiques. Cette approche est préférable à la simple réplication (over-sampling naïf) car elle enrichit la diversité des exemples d'entraînement, réduisant le risque de sur-apprentissage. Il est crucial de souligner que SMOTE n'a été appliqué qu'au jeu d'entraînement, jamais aux données de test, afin de garantir l'intégrité de l'évaluation.

Découpage train/test et validation croisée

Le jeu de données a été découpé en un ensemble d'entraînement (80 %) et un ensemble de test (20 %), avec stratification pour conserver les proportions des classes. Une validation croisée à 5 plis (5-fold cross-validation) a été systématiquement utilisée lors de la phase d'optimisation des hyperparamètres, afin d'obtenir des estimations robustes des performances et d'éviter le sur-apprentissage.

III. Analyse non Supervisée — Clustering

III.1 Choix et présentation des algorithmes

Le clustering non supervisé vise à découvrir la structure sous-jacente des données sans utiliser les étiquettes de classe (Saine / En difficulté / En faillite). L'objectif est double : d'une part, vérifier si les données financières présentent naturellement une structure en groupes cohérente avec le statut légal des entreprises ; d'autre part, identifier des profils financiers atypiques (outliers) qui ne rentrent pas facilement dans les catégories établies. Trois algorithmes ont été retenus pour leur complémentarité méthodologique.

K-Means

K-Means est l'algorithme de clustering le plus utilisé en pratique. Il partitionne les données en K groupes en minimisant la somme des distances euclidiennes intra-cluster (inertie). Son principal avantage est sa simplicité et son efficacité computationnelle. Sa limite principale est l'hypothèse de clusters sphériques de taille comparable, rarement vérifiée dans des données financières réelles. Le choix du nombre optimal de clusters K a été réalisé via la méthode du coude (Elbow Method) et le score de silhouette, qui mesure pour chaque observation la cohésion interne de son cluster par rapport aux clusters voisins. Le score de silhouette maximal a été obtenu pour K=3, ce qui correspond intuitivement aux trois classes de la variable cible.

DBSCAN

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) adopte une approche radicalement différente : il définit les clusters comme des régions de haute densité séparées par des régions de faible densité. Son avantage majeur est sa capacité à identifier des outliers (points de bruit) et à découvrir des clusters de forme arbitraire, sans nécessiter de spécifier a priori le nombre de clusters. Dans le contexte de la prédiction de faillite, cette capacité à isoler les outliers est particulièrement précieuse : les entreprises en faillite peuvent présenter des profils financiers très atypiques qui s'éloignent des patterns habituels. Les hyperparamètres epsilon (rayon de voisinage) et min_samples ont été optimisés par grid search.

Agglomerative Clustering (Classification Ascendante Hiérarchique)

L'algorithme de clustering agglomératif (ou Classification Ascendante Hiérarchique - CAH) construit une hiérarchie de clusters de façon bottom-up : chaque observation commence comme son propre cluster, puis les clusters les plus proches sont successivement fusionnés. La visualisation sous forme de dendrogramme permet d'explorer les relations de similarité entre entreprises à différents niveaux de granularité et d'identifier le nombre optimal de clusters à retenir. La distance de Ward a été utilisée comme critère de fusion, minimisant la variance intra-cluster à chaque étape.

III.2 Résultats et interprétation

Visualisation par ACP

Pour visualiser les clusters dans un espace de dimension 2, une Analyse en Composantes Principales (ACP) a été appliquée. Les deux premières composantes principales capturent environ 58 % de la variance totale des données, ce qui constitue une réduction dimensionnelle acceptable pour une visualisation exploratoire. Les axes

principaux correspondent approximativement à un premier axe de solvabilité/levier financier et à un second axe d'activité/rentabilité.

La projection des clusters K-Means (K=3) dans le plan factoriel ACP révèle une bonne séparation du Cluster 1 (PME saines, regroupées dans le quadrant positif du premier axe) et du Cluster 3 (PME en situation critique, dans le quadrant négatif). En revanche, le Cluster 2 présente une zone de chevauchement significative avec les deux autres clusters, correspondant aux entreprises « en difficulté » dont le profil financier est intermédiaire et flou.

Correspondance clusters / statuts réels

La comparaison entre les labels de clusters et les étiquettes réelles (disponibles a posteriori) constitue l'évaluation la plus instructive du clustering. Elle révèle une correspondance imparfaite mais significative :

Tableau 3 : Matrice de correspondance clusters K-Means vs statuts réels

Cluster K-Means	PME Saine (%)	En difficulté (%)	En faillite (%)	Interprétation
Cluster 1	76 %	18 %	6 %	Majoritairement saines
Cluster 2	31 %	52 %	17 %	Profil intermédiaire (zone grise)
Cluster 3	8 %	28 %	64 %	Majoritairement en faillite

Ce tableau appelle plusieurs commentaires analytiques. Premièrement, la concordance entre les clusters et les statuts réels est statistiquement significative (test du Chi² avec $p < 0{,}001$), ce qui confirme que les variables financières retenues contiennent bien de l'information discriminante sur le risque de faillite. Deuxièmement, la « zone grise » du Cluster 2 qui mélange les trois catégories — illustre la complexité de l'évaluation financière : les variables comptables seules ne suffisent pas à tracer une frontière nette entre une entreprise temporairement en difficulté et une entreprise fondamentalement insolvable. Troisièmement, les outliers identifiés par DBSCAN correspondent majoritairement à des cas extrêmes : entreprises avec des niveaux de levier financier pathologiques (ratio > 10) ou des délais de paiement supérieurs à 200 jours.

III.3 Limites et apports du clustering

Le clustering non supervisé, dans ce contexte, n'a pas vocation à remplacer les modèles de classification supervisée. Sa valeur réside dans sa capacité à explorer la structure des données sans a priori, à identifier des profils atypiques et à fournir une première compréhension intuitive de la distribution du risque. Il révèle notamment que le risque de faillite ne suit pas une logique binaire (sain vs. en faillite) mais s'inscrit dans un continuum graduel, ce qui justifie pleinement l'approche par classification supervisée à trois classes plutôt qu'une simple classification binaire.

IV. Modélisation Supervisée et Comparaison

IV.1 Présentation des modèles de Machine Learning

Régression Logistique

La régression logistique constitue le modèle de référence (baseline) de cette étude. Malgré sa simplicité apparente, elle offre plusieurs avantages : interprétabilité directe des coefficients, temps d'entraînement minimal, et base de comparaison stable pour évaluer le gain apporté par les modèles plus complexes. Dans sa version multiclasse, elle utilise la fonction softmax pour produire des probabilités d'appartenance à chacune des trois classes. Une régularisation L2 (Ridge) a été appliquée pour limiter le sur-apprentissage, avec le paramètre de régularisation C optimisé par validation croisée.

Résultat : La régression logistique atteint une accuracy de classification correcte d'environ 72 % sur le jeu de test, avec des performances inégales selon les classes : excellente précision pour la classe « Saine » (qui représente la majorité des observations), mais rappel insuffisant pour la classe « En faillite » où elle manque environ 30 % des cas. Ce résultat s'explique par la nature des frontières de décision de la régression logistique, qui sont linéaires : les interactions non linéaires entre ratios financiers par exemple, l'effet combiné d'un levier élevé ET d'une liquidité faible ne peuvent pas être capturées par un hyperplan séparateur.

Random Forest

Le Random Forest est un algorithme d'ensemble (ensemble learning) qui construit un grand nombre d'arbres de décision indépendants sur des sous-échantillons aléatoires des données et des variables, puis agrège leurs prédictions par vote majoritaire. Cette approche de bagging (Bootstrap Aggregating) réduit la variance du modèle sans augmenter le biais, conduisant à de très bonnes performances en généralisation. Les hyperparamètres clés optimisés par grid search incluent le nombre d'arbres (n_estimators = 300), la profondeur maximale (max_depth = 15), et le nombre de variables considérées à chaque split (max_features = sqrt).

Résultat : Le Random Forest surperforme nettement la régression logistique avec une accuracy de 89 % sur le jeu de test. Plus important, sa performance est équilibrée entre les trois classes, avec un F1-score de 0,91 pour la classe « Saine », 0,87 pour « En difficulté » et 0,88 pour « En faillite ». La capacité du Random Forest à capturer les interactions non linéaires entre variables notamment l'effet conjoint du délai de paiement et du levier financier explique en grande partie sa supériorité sur la régression logistique. Son robustesse à la multi-colinéarité constitue également un avantage décisif dans ce contexte.

XGBoost

XGBoost (eXtreme Gradient Boosting, Chen & Guestrin, 2016) est un algorithme de boosting qui construit les arbres de décision séquentiellement, chaque nouvel arbre étant entraîné à corriger les erreurs résiduelles du modèle précédent, en suivant le gradient de la fonction de perte. Contrairement au bagging du Random Forest, le boosting réduit à la fois le biais et la variance. XGBoost intègre plusieurs mécanismes de régularisation (L1, L2, sous-échantillonnage des observations et des colonnes) qui lui permettent d'éviter le sur-apprentissage même sur des jeux de données de petite taille. Les hyperparamètres ont été optimisés par recherche bayésienne : learning_rate = 0.05, n_estimators = 500, max_depth = 6, subsample = 0.8, colsample_bytree = 0.8.

Résultat : XGBoost atteint l'accuracy maximale de 92 % sur le jeu de test, avec un F1-score macro de 0,91. Il se distingue particulièrement dans la détection des PME en faillite (rappel de 0,93), ce qui est la performance la plus critique dans une application de scoring de risque. Sa capacité à modéliser des interactions d'ordre élevé entre variables financières lui permet de distinguer des profils subtils — comme une PME présentant un levier élevé compensé par une forte rotation des actifs — que les autres modèles classent incorrectement.

IV.2 Métriques d'évaluation

L'accuracy seule est une métrique insuffisante en contexte de déséquilibre des classes. L'évaluation s'est appuyée sur un ensemble complet de métriques : precision (proportion de prédictions positives correctes), recall (proportion de vrais positifs détectés), F1-score (moyenne harmonique de la précision et du rappel), et AUC-ROC (aire sous la courbe ROC, qui mesure la capacité discriminante du modèle indépendamment du seuil de décision). L'AUC-ROC est calculée selon une approche One-vs-Rest pour les problèmes multiclasses.

Tableau 4 : Résultats détaillés des métriques d'évaluation (jeu de test)

Modèle	Accuracy	F1 Saine	F1 Difficulté	F1 Faillite	AUC-ROC macro
Régression Logistique	72 %	0.81	0.68	0.71	0.84
Random Forest	89 %	0.91	0.87	0.88	0.96
XGBoost	92 %	0.93	0.90	0.93	0.98
Altman Z-Score (approché)	61 %	0.72	0.54	0.58	0.77

Ces résultats appellent plusieurs observations. L'écart de 20 points d'accuracy entre la régression logistique et XGBoost confirme que les relations entre variables financières et risque de faillite sont fondamentalement non linéaires, justifiant l'utilisation d'algorithmes capables de modéliser cette complexité. L'AUC-ROC de 0,98 pour XGBoost est remarquable : elle signifie que dans 98 % des paires (PME saine, PME en faillite) tirées au hasard, le modèle attribue correctement une probabilité de faillite plus élevée à la PME effectivement en faillite. Enfin, le score très faible du Z-Score d'Altman dans ce contexte confirme son inadaptation à l'écosystème PME marocain.

IV.3 Comparaison avec l'Altman Z-Score

Le Z-Score d'Altman a été calculé en approchant ses cinq composantes à partir des variables disponibles dans notre jeu de données, en les normalisant pour les rendre comparables. Le score obtenu est interprété selon les seuils classiques : $Z > 2{,}99$ (zone saine), $1{,}81 < Z < 2{,}99$ (zone grise), $Z < 1{,}81$ (zone de détresse). Cette approximation introduit certes une source d'imprécision notamment pour la variable de valeur marchande des capitaux propres, absente pour les PME non cotées et remplacée par la valeur comptable mais elle permet une comparaison valide des approches.

Les résultats confirment la sous-performance du Z-Score dans ce contexte. Outre les problèmes de calibration évoqués précédemment, l'analyse des erreurs révèle deux biais

systématiques : le Z-Score tend à sur-classer en « zone saine » des PME marocaines présentant des délais de paiement très élevés (son ignore complet de cette variable lui fait manquer l'un des signaux les plus importants), et il tend à mal classer les PME à fort levier opérationnel dans des secteurs à marges faibles (commerce, distribution), qui sont pourtant très représentés dans le tissu PME marocain.

V. Explicabilité par SHAP

V.1 Principe et enjeux de l'explicabilité

L'un des reproches les plus fréquemment adressés aux algorithmes d'apprentissage automatique avancés (Random Forest, XGBoost, réseaux de neurones) est leur caractère de « boîte noire » : si leurs performances prédictives sont supérieures aux méthodes traditionnelles, ils ne permettent pas d'expliquer pourquoi une prédiction particulière a été faite. Or, dans le domaine du crédit et de la décision financière, l'explicabilité est non seulement une exigence réglementaire (le Règlement Général sur la Protection des Données européen impose un « droit à l'explication »), mais aussi une nécessité opérationnelle : un analyste crédit ne peut pas justifier un refus de financement par « le modèle l'a dit ».

Les valeurs SHAP (SHapley Additive exPlanations), développées par Lundberg & Lee (2017), constituent la réponse la plus rigoureuse à ce défi. Fondées sur la théorie des jeux coopératifs (valeurs de Shapley de Lloyd Shapley, Prix Nobel d'Économie 2012), elles permettent d'attribuer à chaque variable une contribution marginale à la prédiction du modèle pour chaque observation individuelle. Formellement, la valeur SHAP d'une variable j pour une observation i mesure la variation moyenne de la prédiction lorsque la variable j est incluse dans le modèle, calculée sur toutes les coalitions possibles de variables.

Propriétés fondamentales des valeurs SHAP

• Efficacité : la somme des valeurs SHAP de toutes les variables pour une observation i est égale à la différence entre la prédiction du modèle pour i et la prédiction moyenne globale.

• Symétrie : deux variables ayant la même contribution marginale reçoivent la même valeur SHAP.

• Sensibilité : une variable n'ayant aucun impact sur la prédiction reçoit une valeur SHAP nulle.

• Consistance : si une variable augmente sa contribution dans tous les contextes possibles, sa valeur SHAP ne peut que croître.

V.2 Résultats et interprétation des valeurs SHAP

Importance globale des variables

L'importance globale des variables est calculée comme la moyenne des valeurs absolues des valeurs SHAP sur l'ensemble du jeu de test. Elle fournit un classement des variables par ordre d'influence moyenne sur les prédictions du modèle XGBoost.

Tableau 5 : Classement SHAP des variables — Impact moyen sur la prédiction de faillite

Rang	Variable	SHAP moyen (|val|)	Direction principale	Interprétation analytique
1	Délai de paiement clients (jours)	0.412	↑ risque si élevé	Premier facteur de basculement vers la faillite

2	Ratio de solvabilité	0.387	↑ risque si faible	Pilier fondamental de la santé financière
3	Levier financier	0.298	↑ risque si élevé	Multiplicateur de vulnérabilité
4	Rentabilité des actifs (ROA)	0.251	↑ risque si négatif	Signal de destruction de valeur
5	Liquidité générale	0.198	↑ risque si < 1	Alerte précoce de tension de trésorerie
6	Rotation des actifs	0.134	Variable	Indicateur d'activité (effet ambigu)
7	Délai de paiement fournisseurs (j.)	0.119	Complexe	Allongement = stress OU négociation
8	Marge brute	0.098	↑ risque si faible	Signal d'érosion de la compétitivité

L'analyse de ce tableau appelle plusieurs commentaires importants. Le classement en tête du délai de paiement clients est remarquable et constitue la principale contribution de cette étude par rapport aux approches traditionnelles : cette variable, absente du Z-Score d'Altman, s'avère être le meilleur prédicteur de faillite dans le contexte marocain. Son interprétation est intuitive : une PME dont les clients règlent tardivement est confrontée à un besoin en fonds de roulement (BFR) croissant, qui peut rapidement dépasser sa capacité de financement, conduisant à une situation de cessation de paiement même en présence d'une rentabilité comptable positive.

Le ratio de solvabilité confirme son rôle de pilier de la santé financière à long terme. Une PME fortement endettée (faible solvabilité) dispose d'une marge de manœuvre réduite pour absorber les chocs baisse du chiffre d'affaires, allongement des délais de paiement, hausse des intrants. L'effet de levier financier agit comme un amplificateur : à niveau de rentabilité égal, une PME endettée supporte des charges financières plus élevées qui grèvent davantage sa trésorerie.

Effets d'interaction

L'un des apports les plus précieux des valeurs SHAP réside dans leur capacité à révéler des effets d'interaction entre variables ce qui est impossible avec des coefficients linéaires statiques comme ceux du Z-Score. Les graphiques de dépendance SHAP montrent par exemple que l'impact du levier financier sur le risque de faillite n'est pas constant : il est faible lorsque la rentabilité des actifs est élevée (la PME peut rembourser sa dette), mais devient très élevé lorsque le ROA est négatif ou proche de zéro. Cette interaction entre levier et rentabilité illustre le concept de « fragilité financière conditionnelle » : une structure financière risquée ne devient dangereuse que dans certaines conditions de performance opérationnelle.

VI. Analyse Spécifique au Contexte Marocain

L'une des contributions essentielles de cette étude réside dans son ancrage dans la réalité spécifique de l'économie marocaine. Les modèles de scoring de crédit importés des États-Unis ou d'Europe sont souvent mal adaptés aux marchés émergents, non pas en raison d'une infériorité théorique, mais parce qu'ils ont été construits sur des hypothèses (structures de marché, comportements de paiement, cadre légal) qui ne correspondent pas aux réalités locales. Cette section articule les principales spécificités du contexte marocain qui influencent la modélisation du risque de faillite des PME.

VI.1 La problématique des délais de paiement

La problématique des délais de paiement inter-entreprises constitue sans doute la spécificité la plus déterminante du contexte marocain. Contrairement à la France où la loi LME (Loi de Modernisation de l'Économie, 2008) plafonne légalement les délais de paiement à 60 jours, le Maroc ne dispose que de mécanismes légaux partiels et peu contraignants. En pratique, les grandes entreprises et les donneurs d'ordres publics imposent souvent à leurs fournisseurs PME des délais de paiement excédant 90, voire 120 jours.

Pour une PME dont le cycle d'exploitation est court, cette situation génère un effet de ciseaux dévastateur : elle doit payer ses fournisseurs et ses salariés (en général sous 30 à 60 jours) tout en attendant plusieurs mois le règlement de ses propres créances. Le besoin en fonds de roulement (BFR) s'envole, et la trésorerie disponible ne suffit plus à couvrir les engagements courants. Le crédit bancaire de trésorerie lorsqu'il est accessible ne couvre qu'une fraction du besoin réel et à un coût souvent prohibitif pour les PME. Ce scénario, couramment observé dans notre jeu de données, explique pourquoi des PME affichant une rentabilité comptable positive peuvent se retrouver en état de cessation de paiement : leur crise est une crise de liquidité, non de solvabilité fondamentale.

Notre modèle ML capte parfaitement ce mécanisme : la valeur SHAP du délai de paiement clients est la plus élevée de toutes les variables, et son effet est fortement asymétrique des délais supérieurs à 120 jours génèrent une contribution SHAP vers la classe « En faillite » qui dépasse celle d'un ratio de solvabilité médiocre. Ce résultat a des implications directes pour la politique économique : un renforcement de la loi sur les délais de paiement au Maroc pourrait avoir un impact significatif sur le taux de défaillance des PME.

VI.2 L'accès au financement bancaire

Le deuxième facteur de vulnérabilité spécifique des PME marocaines est leur accès limité et coûteux au financement bancaire. Selon les données de Bank Al-Maghrib, moins de 30 % des PME marocaines ont accès à un crédit bancaire formel, contre plus de 70 % dans les pays de l'OCDE. Les raisons sont multiples : asymétrie d'information (les PME marocaines présentent souvent des comptes peu formalisés, rendant l'analyse de crédit difficile), manque de garanties réelles, risque perçu élevé, et coût du crédit prohibitif (taux effectifs globaux souvent supérieurs à 8-10 % pour les PME contre 2-4 % en zone euro).

Cette contrainte financière se traduit dans les données par un recours fréquent à l'endettement fournisseur (allongement des dettes fournisseurs comme moyen de financement implicite) et par un niveau de levier financier élevé chez les PME qui ont accès au crédit bancaire. Elle renforce également la pertinence de notre modèle : un outil de scoring fiable, capable de distinguer les PME effectivement risquées des PME

temporairement en difficulté de trésorerie, pourrait aider les banques à étendre leur couverture du marché PME de façon maîtrisée.

VI.3 Hétérogénéité sectorielle

Le tissu PME marocain est caractérisé par une forte hétérogénéité sectorielle qui influence directement la pertinence des ratios financiers utilisés. Les PME du secteur BTP sont exposées à des cycles de facturation très longs et à des risques liés aux marchés publics (retards de paiement de l'État, révision des prix). Les PME du commerce de gros opèrent avec des marges très faibles et une forte rotation des stocks, rendant leur liquidité extrêmement sensible aux variations d'activité. Les PME industrielles supportent des charges fixes élevées et un risque de change sur les matières premières importées.

La force d'un modèle ML par rapport à une approche paramétrique statique comme le Z-Score est sa capacité à s'adapter implicitement à ces différences sectorielles : en apprenant des patterns différents pour des sous-ensembles de données aux caractéristiques distinctes, il peut produire des prédictions contextualisées sans nécessiter la construction de modèles séparés par secteur (du moins dans la mesure où le jeu de données est suffisamment représentatif de chaque secteur).

VII. Conclusion et Recommandations

VII.1 Synthèse des résultats

Cette étude a démontré, à travers une démarche rigoureuse combinant exploration non supervisée, modélisation supervisée et analyse d'explicabilité, que les algorithmes de Machine Learning et en particulier XGBoost et Random Forest sont significativement supérieurs au modèle classique d'Altman Z-Score pour la prédiction du risque de faillite des PME marocaines. L'accuracy de 92 % obtenue par XGBoost sur le jeu de test, contre 61 % pour le Z-Score approché, traduit un écart de performance qui ne peut pas être attribué à des artefacts méthodologiques : il reflète une différence de capacité fondamentale à modéliser la complexité non linéaire des trajectoires de défaillance financière.

Trois résultats méritent d'être soulignés comme contributions originales de cette étude. Premièrement, la confirmation empirique du rôle primordial des délais de paiement dans le risque de faillite des PME marocaines : avec une importance SHAP de 0,412 la plus élevée de toutes les variables, le délai de paiement clients s'impose comme le premier signal d'alerte à surveiller, devant même le ratio de solvabilité. Deuxièmement, la mise en évidence d'effets d'interaction entre variables (notamment entre levier financier et rentabilité des actifs) qui ne peuvent être capturés que par des approches non linéaires. Troisièmement, la démonstration que le clustering non supervisé, tout en étant incapable de reproduire parfaitement les catégories légales, révèle une structure de risque en gradient qui plaide pour une approche probabiliste (probabilité de défaut) plutôt que catégorielle.

VII.2 Modèle recommandé pour le déploiement

Pour une application opérationnelle dans un contexte bancaire ou institutionnel marocain, le Random Forest est recommandé en priorité, devant XGBoost, malgré une légère infériorité en termes d'accuracy pure (89 % vs 92 %). Trois raisons motivent ce choix. Premièrement, le Random Forest présente une meilleure robustesse à la dérive des données (data drift) dans le temps : les procédures de boosting d'XGBoost peuvent être plus sensibles aux changements de distribution des variables financières en période de crise ou de choc macroéconomique. Deuxièmement, son mécanisme d'out-of-bag error permet une estimation de la performance sans nécessiter un jeu de validation séparé, ce qui est précieux lorsque les données labellisées sont rares. Troisièmement, son implémentation est plus simple et sa maintenance plus accessible pour des équipes de risk management sans expertise avancée en Data Science.

VII.3 Recommandations opérationnelles

Sur la base des résultats de cette étude, trois recommandations opérationnelles sont formulées à destination des acteurs financiers et des décideurs :

1. Déploiement d'un Early Warning System (Système d'Alerte Précoce) : L'algorithme Random Forest, déployé via une API REST accessible depuis les systèmes d'information des banques partenaires, permettrait de calculer en temps réel un score de risque pour chaque PME cliente, à partir de ses derniers états financiers déposés à l'OMPIC ou communiqués dans le cadre d'une demande de crédit. Ce score, accompagné des valeurs SHAP individuelles sous forme de graphique en cascade (waterfall chart), fournirait à l'analyste crédit une explication structurée et

personnalisée de la prédiction, répondant ainsi aux exigences d'explicabilité réglementaire et opérationnelle.

2. Interface d'aide à la décision pour les analystes risques : La mise en place d'un tableau de bord intégrant la probabilité de défaut estimée par le modèle, le classement des variables de risque par importance SHAP pour la PME considérée, et une comparaison avec les médianes sectorielles, permettrait aux analystes de contextualiser les alertes générées par le modèle. Cette interface favoriserait une utilisation augmentée de l'IA où le modèle assiste et documente la décision humaine plutôt que de la remplacer et faciliterait l'adoption par des équipes peu habituées aux outils quantitatifs.
3. Plaidoyer pour une politique de réduction des délais de paiement : Les résultats de cette étude fournissent une base empirique solide pour plaider auprès des autorités marocaines (Ministère de l'Économie, Bank Al-Maghrib, CGEM) en faveur d'un renforcement du cadre légal sur les délais de paiement inter-entreprises. La démonstration quantitative que le délai de paiement clients est le premier prédicteur de faillite des PME au Maroc constitue un argument de politique publique puissant : chaque jour de réduction du délai moyen de paiement se traduit statistiquement par une réduction du taux de défaillance des PME.

VII.4 Limites et perspectives

Cette étude comporte plusieurs limites qui ouvrent des perspectives de recherche future. En premier lieu, la qualité et la représentativité du jeu de données conditionne la validité externe des conclusions : les ratios financiers des PME marocaines sont souvent affectés par des pratiques de comptabilité informelle ou d'optimisation fiscale qui réduisent leur fiabilité en tant que signaux de détresse. Des travaux futurs pourraient intégrer des données qualitatives complémentaires (secteur d'activité détaillé, âge de l'entreprise, caractéristiques du dirigeant) et des données alternatives (comportement de paiement électronique, patterns de consultation bancaire).

En second lieu, la nature statique du modèle actuel qui prédit à partir d'une photographie financière annuelle pourrait être enrichie par une approche dynamique intégrant les trajectoires temporelles des ratios. Des modèles de séries temporelles (LSTM, modèles de survie) permettraient de détecter non seulement la situation actuelle d'une PME, mais aussi la vitesse et la direction de sa dégradation financière, fournissant ainsi une fenêtre temporelle plus précise pour l'intervention préventive.

Enfin, l'extension géographique de l'approche à d'autres économies africaines partageant des caractéristiques similaires (fortes économies informelles, délais de paiement élevés, accès limité au crédit) pourrait révéler des patterns transversaux et conduire à la construction de modèles de scoring régionaux plus robustes.

Bibliographie & Webographie

Altman, E. I. (1968). Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. Journal of Finance, 23(4), 589–609. [Article fondateur du Z-Score, toujours référence incontournable de la littérature sur la prédiction de faillite.]

Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5–32. [Article original introduisant l'algorithme Random Forest, fondement théorique de l'un des modèles utilisés.]

Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785–794. [Article original d'XGBoost, modèle le plus performant de l'étude.]

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. Journal of Artificial Intelligence Research, 16, 321–357. [Base théorique de la technique de rééquilibrage des classes utilisée dans le pré-traitement.]

Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. Advances in Neural Information Processing Systems (NeurIPS), 30. [Article fondateur des valeurs SHAP, utilisées pour l'explicabilité des modèles.]

Bank Al-Maghrib (2023). Rapport annuel sur la stabilité financière. Chapitre IV : Financement des PME et risque de crédit. Rabat : Bank Al-Maghrib.

OMPIC — Office Marocain de la Propriété Industrielle et Commerciale (2024). Tableau de bord des défaillances d'entreprises au Maroc — données annuelles. Disponible sur : www.ompic.ma

Direction des Études et des Prévisions Financières — DEPF (2023). Rapport sur la compétitivité des PME marocaines. Ministère de l'Économie et des Finances, Rabat.

Mselmi, N., Lahiani, A., & Hamza, T. (2017). Financial distress prediction: The case of French small and medium-sized firms. International Review of Financial Analysis, 50, 67–80. [Étude de référence sur la prédiction de détresse financière pour les PME, méthodologie comparable.]

Scikit-learn developers (2024). Scikit-learn: Machine Learning in Python. Documentation officielle, version 1.4. Disponible sur : scikit-learn.org

Lundberg, S. M. (2024). SHAP (SHapley Additive exPlanations) — Documentation et tutoriels. Disponible sur : shap.readthedocs.io