Université Hassan Ier
ÉCOLE NATIONALE DE COMMERCE ET DE GESTION
DE SETTAT

RAPPORT DE PROJET

Prédiction du Risque de Faillite des PME Marocaines

Comment segmenter et prédire efficacement le risque de faillite des PME marocaines ?

Module : Intelligence artificielle

Réalisé par : Chérestal Déborah Nativa (N° 22008149)
Doumbouya Moussa (N° 22007303)
Encadré par : Abderrahim Larhlimi

SOMMAIRE

I. Introduction & Contexte **3**

II. Exploration et Préparation des Données (EDA) **3**

II.1 Analyse uni/bi variée 3

II.2 Prétraitement 4

III. Analyse non Supervisée (Clustering) **4**

IV. Modélisation Supervisée et Comparaison **5**

IV.1 Modèles de Machine Learning (ML) 5

IV.2 Comparaison avec l'Altman Z-Score 5

V. Explicabilité par SHAP **6**

VI. Analyse Spécifique au Contexte Marocain **6**

VII. Conclusion et Recommendations **7**

Bibliographie 8

I. Introduction & Contexte

Le tissu économique marocain est majoritairement constitué de Petites et Moyennes Entreprises (PME). Celles-ci sont confrontées à des défis financiers majeurs, notamment l'allongement des délais de paiement et l'accès limité au crédit. Dans ce contexte, la détection précoce du risque de faillite est vitale pour les créanciers, les investisseurs et les dirigeants d'entreprise.

L'objectif de ce projet est de développer un modèle de prédiction du risque de faillite pour les PME marocaines en s'appuyant sur des indicateurs bilanciels et financiers. Nous combinons des approches d'apprentissage non supervisé (clustering) et supervisé (classification par Machine Learning), tout en comparant leurs performances avec le modèle traditionnel d'Altman Z-Score.

II. Exploration et Préparation des Données (EDA)

Les données analysées sont des ratios financiers clés regroupant des indicateurs de Liquidité, de Solvabilité, de Rentabilité, de Levier financier, de Rotation des actifs, ainsi que les Délais de Paiement en Jours — cette dernière variable se révélant particulièrement déterminante dans le contexte marocain.

II.1 Analyse uni/bivariée

L'analyse exploratoire a mis en exergue plusieurs enseignements structurants pour la suite de la modélisation :

- La forte variance des indicateurs de rentabilité, typique des PME en difficulté ou en pleine croissance.
- Un déséquilibre naturel des classes entre les entreprises saines, en difficulté et en faillite.
- Une incidence très prononcée des Délais de Paiement sur la probabilité de basculer en mode « En difficulté ».

II.2 Pré-traitement

Les données ont été standardisées (moyenne nulle et variance unitaire) via un StandardScaler, afin d'éviter qu'une variable ne domine les algorithmes axés sur la distance (tel que K-Means) ou la régularisation (pour la Régression Logistique). La gestion du déséquilibre des classes a été traitée par la technique de sur-échantillonnage SMOTE (Synthetic Minority Over-sampling Technique) avant l'entraînement des algorithmes supervisés.

III. Analyse non Supervisée (Clustering)

Le clustering a été utilisé pour découvrir la structure sous-jacente des données financières. Trois algorithmes ont été mobilisés : K-Means, DBSCAN et Agglomerative Clustering.

La visualisation des clusters via une Analyse en Composantes Principales (ACP) à 2 dimensions montre une bonne séparation de certains groupes. Cependant, le croisement des clusters avec les statuts réels (Sain / En difficulté / Faillite) démontre qu'une structure purement non supervisée n'épouse pas toujours parfaitement les étiquettes légales — les contours de l'état « En difficulté » demeurent flous.

Cela souligne une réalité fondamentale de l'évaluation financière : les variables comptables seules dessinent un gradient de risque plutôt que des catégories hermétiques. Le clustering reste néanmoins indispensable pour détecter des cas atypiques (outliers) et comprendre l'hétérogénéité des entreprises marocaines.

IV. Modélisation Supervisée et Comparaison

IV.1 Modèles de Machine Learning (ML)

Trois modèles supervisés ont été entraînés et évalués sur le jeu de données pré-traité :

- Régression Logistique : constitue une base de référence solide (baseline), mais peine à capturer les interactions non linéaires complexes entre les ratios financiers.
- Random Forest : surperforme nettement la régression logistique. Il s'affranchit de la multi-colinéarité potentielle entre indicateurs de rotation ou de liquidité.
- XGBoost (boosting) : modèle le plus performant en termes d'accuracy globale. Il parvient à distinguer les subtilités entre une PME temporairement illiquide et une PME fondamentalement insolvable.

Tableau 1 : Synthèse comparative des modèles

Modèle	Accuracy	Robustesse	Explicabilité
Régression Logistique	Modérée	Faible (non-linéaire)	Élevée
Random Forest	Très élevée	Élevée	Élevée (SHAP)
XGBoost	Maximale	Très élevée	Élevée (SHAP)
Altman Z-Score	Faible (contexte MA)	Statique / rigide	Coefficients fixes

IV.2 Comparaison avec l'Altman Z-Score

Le Z-Score a été approché à travers une pondération des indicateurs normalisés du jeu de données. Les résultats montrent que les modèles ML (XGBoost et Random Forest en tête) obtiennent une accuracy largement supérieure à celle du modèle d'Altman.

Les limites du Z-Score dans ce contexte sont multiples :

- Conçu initialement sur des firmes industrielles publiques américaines, il accorde un poids trop statique à des variables qui n'ont pas la même portée dans le contexte des PME marocaines (ex. : valeur marchande des capitaux propres).
- Il ignore totalement le poids des délais de paiement, variable pourtant déterminante dans l'économie marocaine.

V. Explicabilité par SHAP

En conformité avec les besoins métiers réclamant des modèles « boîte de verre » (interpretables), l'utilisation des valeurs SHAP (SHapley Additive exPlanations) a permis d'isoler et de quantifier les drivers de risque pour chaque prédiction individuelle.

Tableau 2 : Importance des variables selon les valeurs SHAP

Variable	Impact SHAP	Rôle dans le risque
Délais de paiement (jours)	Très élevé ↑	Driver principal de faillite
Solvabilité	Élevé ↑	Variable explicative majeure
Levier financier	Multiplicateur ×	Amplificateur en cas de baisse de rentabilité
Liquidité	Modéré	Signal précoce de tension

Contrairement au Z-Score dont les coefficients sont statiques, les valeurs SHAP prouvent que le poids d'une variable diverge considérablement selon le profil global de la PME, révélant ainsi des effets d'interaction impossibles à capter par une approche linéaire.

VI. Analyse Spécifique au Contexte Marocain

Le contexte économique marocain se distingue par l'impact destructeur des retards de facturation inter-entreprises. L'introduction de la variable « Délais de paiement en jours » dans le modèle ML permet une modélisation beaucoup plus ancrée dans la réalité du terrain.

Les PME financièrement saines au niveau bilanciel mais souffrant d'un allongement du Délai de Paiement Fournisseur (DPF) sombrent rapidement dans des difficultés de trésorerie. Le Machine Learning valorise correctement cet indicateur, ce que les ratios anglo-saxons standards échouent à mesurer.

Ce constat plaide pour la construction de modèles de scoring « locaux », calibrés sur les spécificités de l'écosystème PME marocain — structure du capital, accès au financement bancaire, culture de paiement — plutôt que d'adapter mécaniquement des modèles étrangers.

VII. Conclusion et Recommandations

Cette étude a démontré que les algorithmes de Machine Learning, en particulier XGBoost et Random Forest, surpassent significativement le modèle classique d'Altman Z-Score pour la prédiction du risque de faillite des PME marocaines. L'intégration des délais de paiement comme variable explicative clé constitue l'apport majeur de cette approche contextualisée.

Modèle recommandé pour le déploiement

Le Random Forest est recommandé pour son équilibre optimal entre performance prédictive et facilité d'explicabilité via les valeurs SHAP. Il constitue la base idéale d'un système d'alerte précoce (Early Warning System).

Recommandations opérationnelles

1. Implémentation d'un Early Warning System : coupler les historiques comptables de l'OMPIC avec l'algorithme ML déployable via API pour remonter automatiquement les alertes aux banques et investisseurs.
2. Priorité à l'explicabilité : fournir aux analystes risques une interface combinant la prédiction de « Probabilité de Défaut » et les graphiques SHAP en cascade pour justifier une décision de refus ou d'octroi de crédit.
3. Focus Trésorerie : au Maroc, « Cash is King ». Les stratégies de gestion du poste clients doivent figurer en amont de toute politique de croissance pour les PME identifiées en zone rouge ou grise par le modèle.

Bibliographie & Webographie

Altman, E. I. (1968). Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. Journal of Finance, 23(4), 589–609.

Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. NeurIPS 2017.

Chawla, N. V., et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique. JAIR, 16, 321–357.

Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. KDD 2016.

Bank Al-Maghrib (2023). Rapport annuel sur la stabilité financière — Chapitre PME. Rabat.

OMPIC (2024). Registre national du commerce — Données sur les défaillances d'entreprises.